초기 100사이클 데이터로 배터리 수명을 예측할 수 있는가

MIT-Stanford 배터리 데이터 EDA와 모델 설계 전략

울산캠퍼스 U114 김현수

데이터 (MIT-Stanford, 139셀 중 129셀 분석)

배치	파일 내	분석	제외	수명 중앙값
Batch 1	46	46	0	858.5
Batch 2	47	39	8	472.0
Batch 3	46	44	2	1,005.5

제외 = 다른 실험 8셀(VarCharge·SLOWCYCLE) + 수명 기록 없음 2셀. Batch 1 학습 · Batch 2 최종 테스트 · Batch 3 추가 검증

보고서 구성 (과제 질문 순서)

Q1	Cycle Life 분포 · 배치 간 비교	2-3쪽
Q2	열화 곡선 · Knee point	4쪽
Q3	ΔQ(V) 곡선 · 피처 추출	5-6쪽
Q4	충전 조건과 수명	7-8쪽
Q5	상관관계 · 멀티콜리니어리티	9쪽
요약	EDA 시사점 → 설계	10쪽
전략	Feature Engineering · 회귀/분류 · Modeling Strategy	11-15쪽
참고	참고문헌 · 분석 재현	16쪽

결론

1. **핵심 피처는 ΔQ 로그분산**이다. 세 배치 모두 수명과 강하게 연결된다(ρ -0.71~-0.87).
2. **회귀로 cycle_life를 예측**한다. 550회 기준 분류는 학습 데이터에 단수명이 거의 없어(1셀) 불가능하다.
3. **Ridge를 주 후보**로, 같은 충전 정책 셀이 섞이지 않게 정책 단위로 나눠 검증한다.

용어

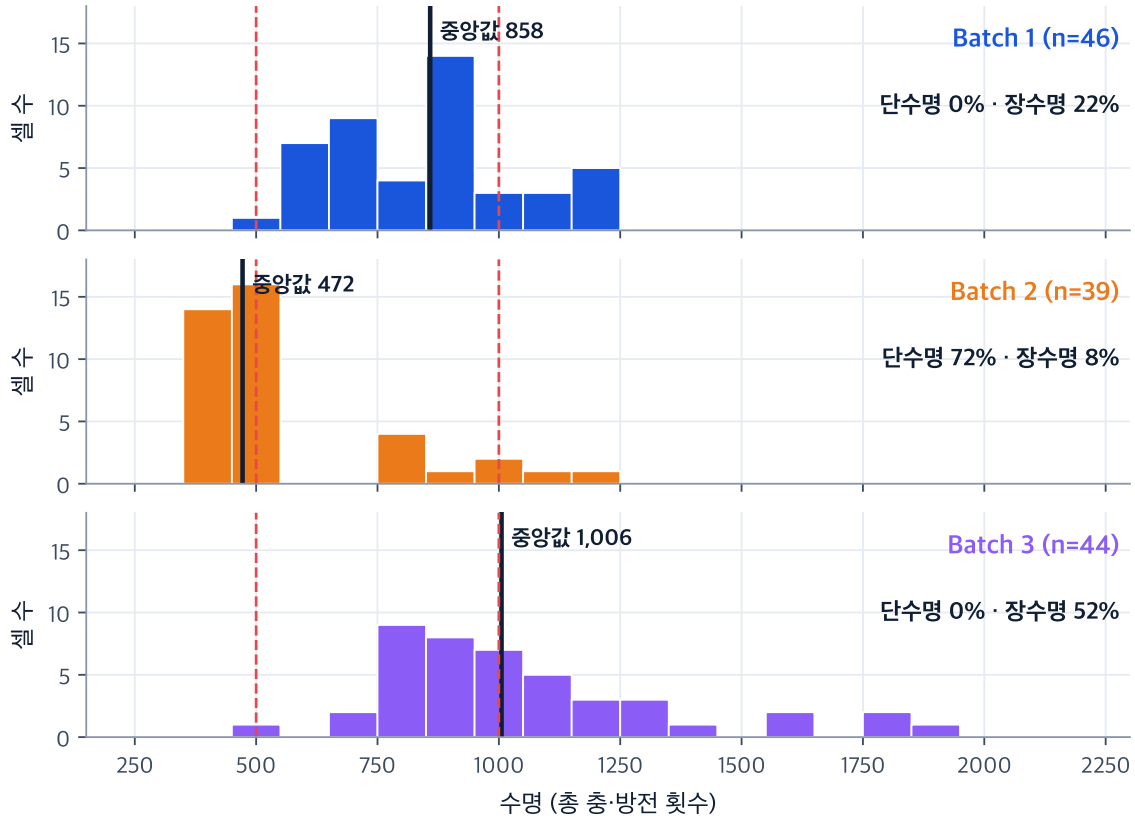
cycle_life	용량이 0.88 Ah(공칭의 80%)가 될 때까지의 충·방전 횟수
ΔQ 로그분산	100회차와 10회차 방전 곡선 차이의 분산(log10)
newstructure	사이클 사이 휴지를 없앤 실험 절차로 측정한 셀
ρ · MAPE	순위상관(−1~1) · 평균 절대 백분율 오차

구성 각 쪽은 과제의 질문에 그래프와 답으로 응답하고, 마지막에 모델 설계에 주는 시사점을 정리했다.

데이터: Severson et al., Nature Energy 2019 · 원본 .mat 3개 배치에서 셀 단위로 추출

Q1-1. Cycle Life 분포는 어떻게 생겼는가?

그림 1. 배치별 수명 히스토그램 150~2,300회 · 점선 = 단수명 500 · 장수명 1,000회



분포 모양은?

배치마다 크게 다르다. 중앙값 858 / 472 / 1,006회. Batch 2만 400~550회에 몰려 있다.

장수명 / 단수명 비율은?

장수명(>1,000) **21.7% / 7.7% / 52.3%**

단수명(<500) **0% / 71.8% / 0%**

이상치 셀은 왜 유독 짧은가?

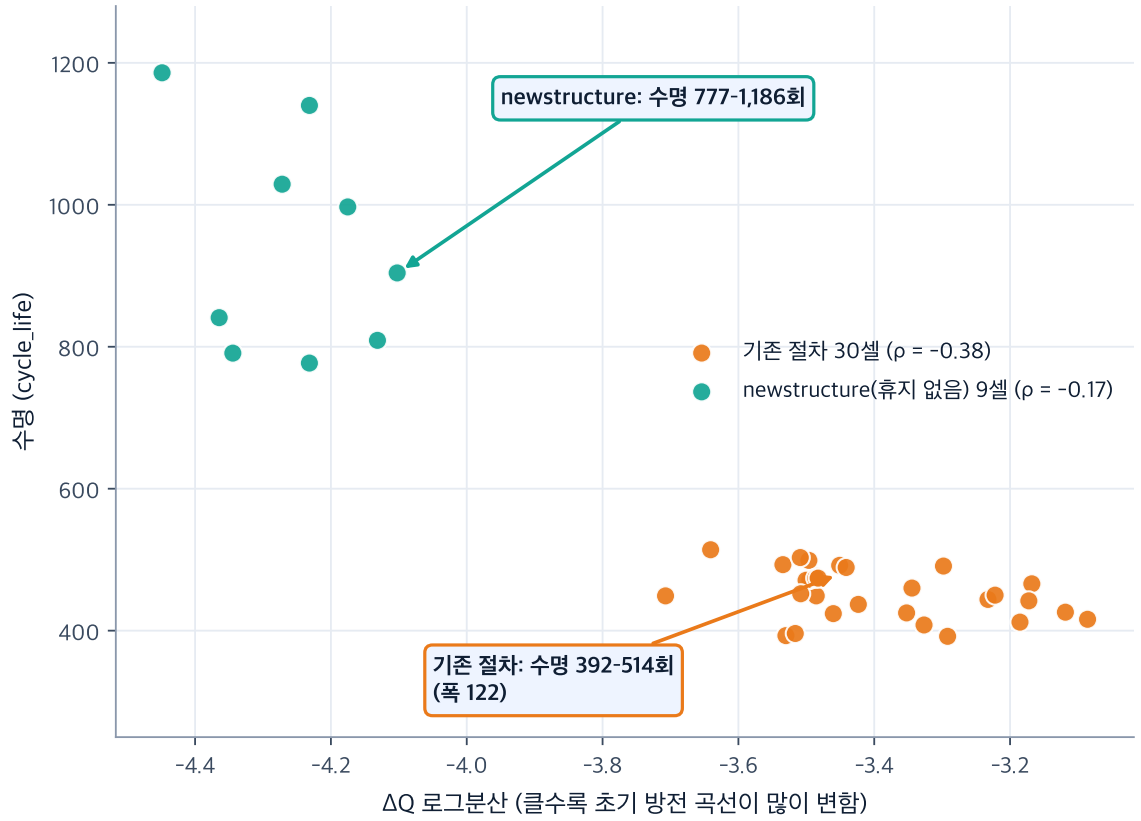
최단 셀(1-21, 2-20)은 **같은 충전 정책의 셀과 함께 짧다**. 셀 결함이 아니라 가혹한 충전 정책 때문이다.

시사점 배치 간 분포 차이가 크다 → Batch 1로만 학습하고 Batch 2는 마지막에 한 번 테스트한다.

n = Batch 1 46, Batch 2 39, Batch 3 44 · 비율은 Batch 1 / 2 / 3 순

Q1-2. Batch 2의 셀은 모두 같은 조건에서 실험되었는가?

그림 2. Batch 2: 실험 절차별 수명 한 점 = 셀 1개



같은 조건인가?

아니다. 9셀은 사이클 사이 휴지를 없앤 절차(newstructure)로 실험됐다. 휴지 10분 → 0.3분, 사이클 약 70분 → 48분.

수명은 어떻게 다른가?

기존 절차 30셀 **392-514회**, newstructure 9셀 **777-1,186회**. 겹치지 않는다.

Batch 3은?

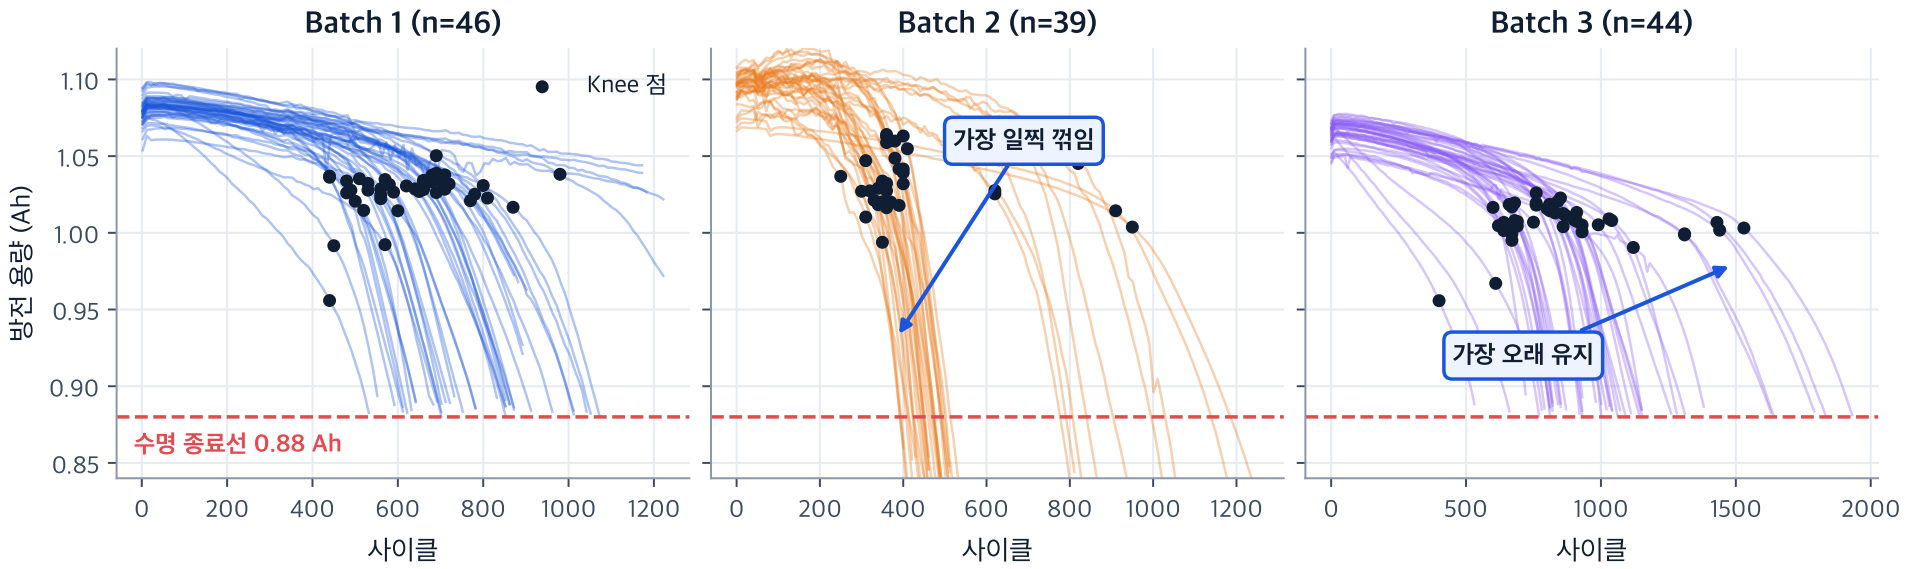
44셀 전부 newstructure다. 배치 간 차이에 절차 차이가 섞여 있다.

시사점 Batch 2 성능은 전체 39셀과 절차별(30·9셀)로 나눠 보고한다.

절차 비교: Batch 2의 같은 정책 4.8C(80%)-4.8C 셀들의 10회차 사이클

Q2. 방전 용량은 어떻게 감소하는가?

그림 3. 사이클별 방전 용량(Qd) 추이 검은 점 = Knee point · 점선 = 수명 종료 0.88 Ah



열화 속도가 일정한가, 가속되는가?

후반에 가속된다. 기울기가 2배 이상 가팔라지는 셀이 42/46, 39/39, 43/44.

Knee point는 어디인가?

중앙값 **630 / 360 / 810회**. 수명이 짧은 배치일수록 일찍 온다.

예측에 쓸 수 있나?

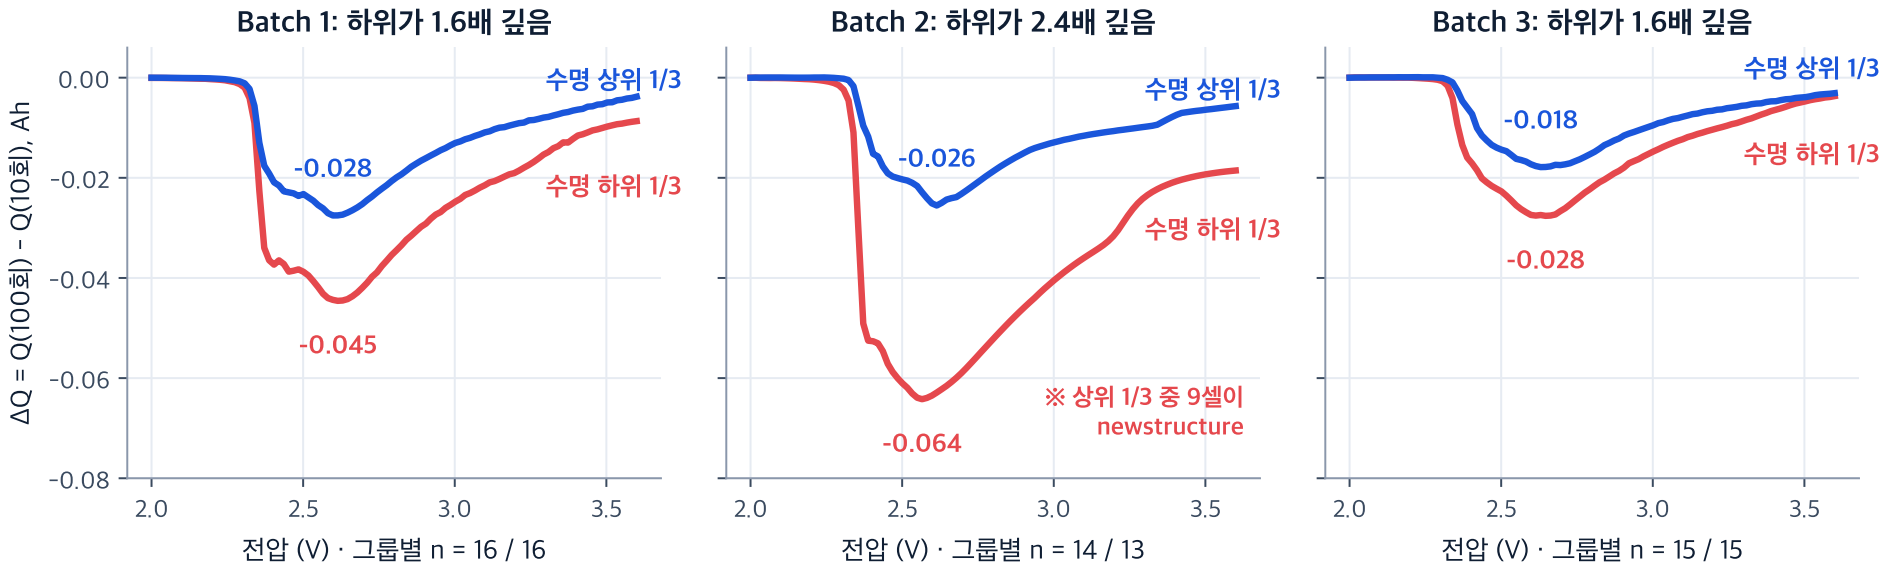
없다. Knee는 수명이 끝나갈 때 나타나는 값이라, 100회차 시점에는 알 수 없다.

시사점 Knee 이전, 겉보기에 비슷한 초기 100회 안에서 수명 차이를 잡는 피처가 필요하다.

Knee = 100회 이후 곡선을 두 직선으로 근사한 꺾임점 (사후 탐색값)

Q3-1. 초기 사이클의 ΔQ(V) 곡선에서 차이가 보이는가?

그림 4. ΔQ(V) = Q(100회) − Q(10회) 배치 안 수명 하위 1/3 vs 상위 1/3의 중앙 곡선



장수명 vs 단수명 형태는?

단수명 셀의 곡선이 더 깊다. 최솟값이 1.6배(Batch 1), 1.6배(Batch 3), 2.4배(Batch 2).

왜 3분위로 나눴나?

Batch 1·3에는 500회 미만 셀이 없어, 배치 안에서 수명 하위·상위 1/3을 비교했다.

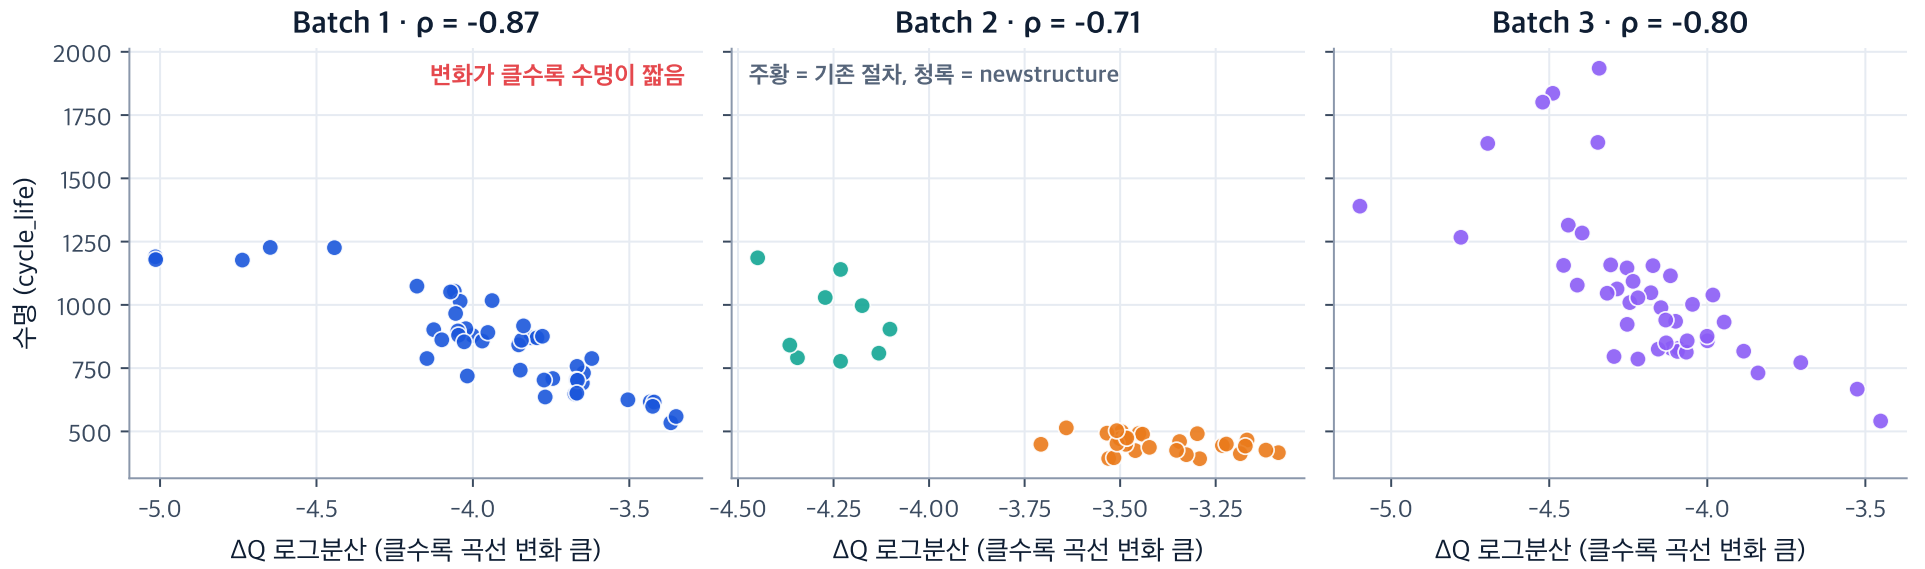
구분할 통계값은?

ΔQ 곡선의 분산(log10)을 피처로 추출했다. 평균·최솟값은 보조.

시사점 ΔQ 로그분산을 1순위 피처로 쓴다.

Q3-2. 추출한 ΔQ 로그분산은 수명을 구분하는가?

그림 5. ΔQ 로그분산 vs 수명 한 점 = 셀 1개



수명과 연결되는가?

그렇다. ρ = -0.87 / -0.71 / -0.80. 곡선 변화가 클수록 수명이 짧다.

관계 형태는?

Batch 1에서 **거의 직선**이다(Pearson -0.89).

배치 간 차이는?

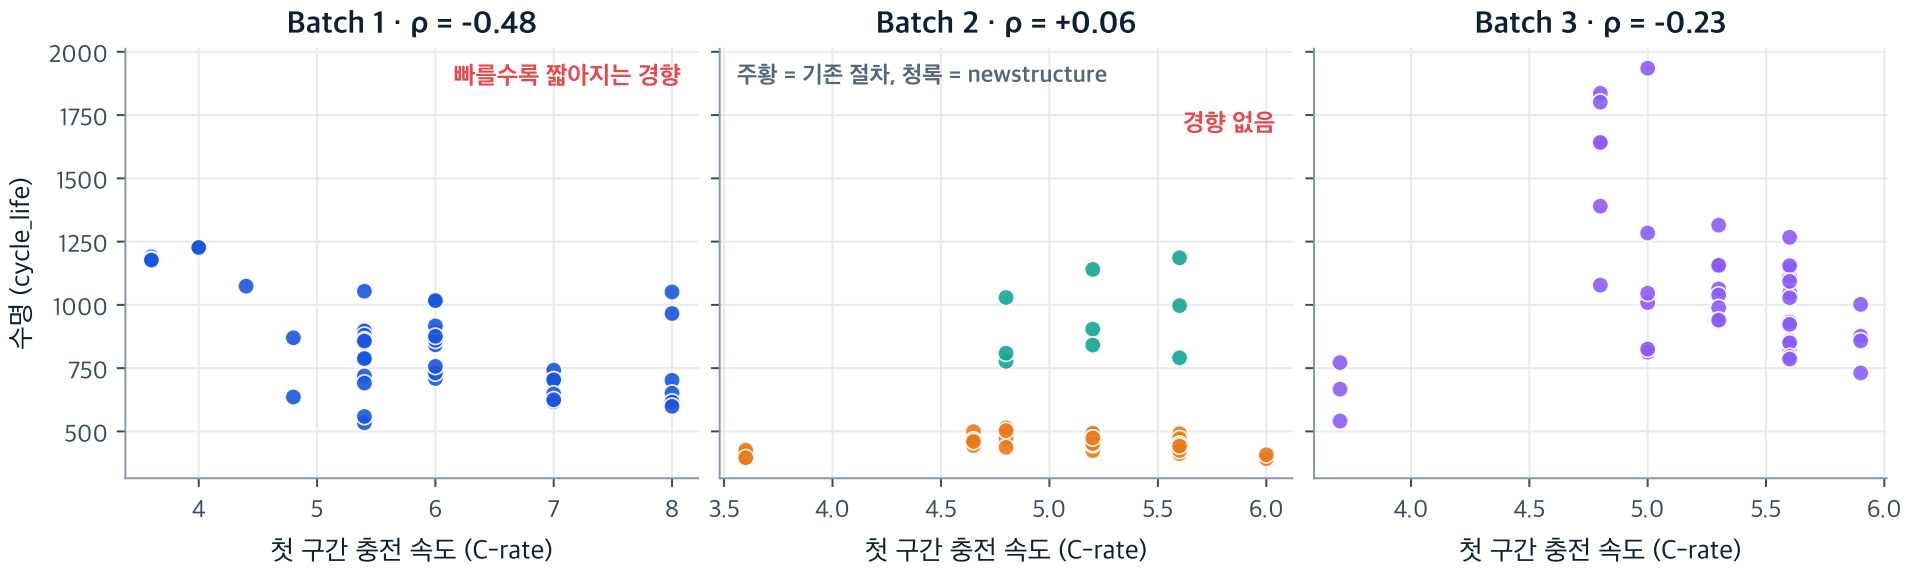
Batch 2의 값은 실험 절차 차이(Q1-2)가 섞여 실제보다 강해 보인다.

시사점 ΔQ 로그분산 하나로 선형 기준 모델부터 만든다.

ρ = Spearman 순위상관 · 129셀

Q4-1. 충전 조건(C-rate)과 수명의 관계는?

그림 6. 첫 구간 충전 속도 vs 수명 C-rate가 클수록 빠른 충전 · 한 점 = 셀 1개



프로토콜별 평균 수명은?

Batch 1 23개 정책 중 최장 4C(80%)-4C **1,226회**, 최단 5.4C(80%)-5.4C **546회**. 2.2배 차이.

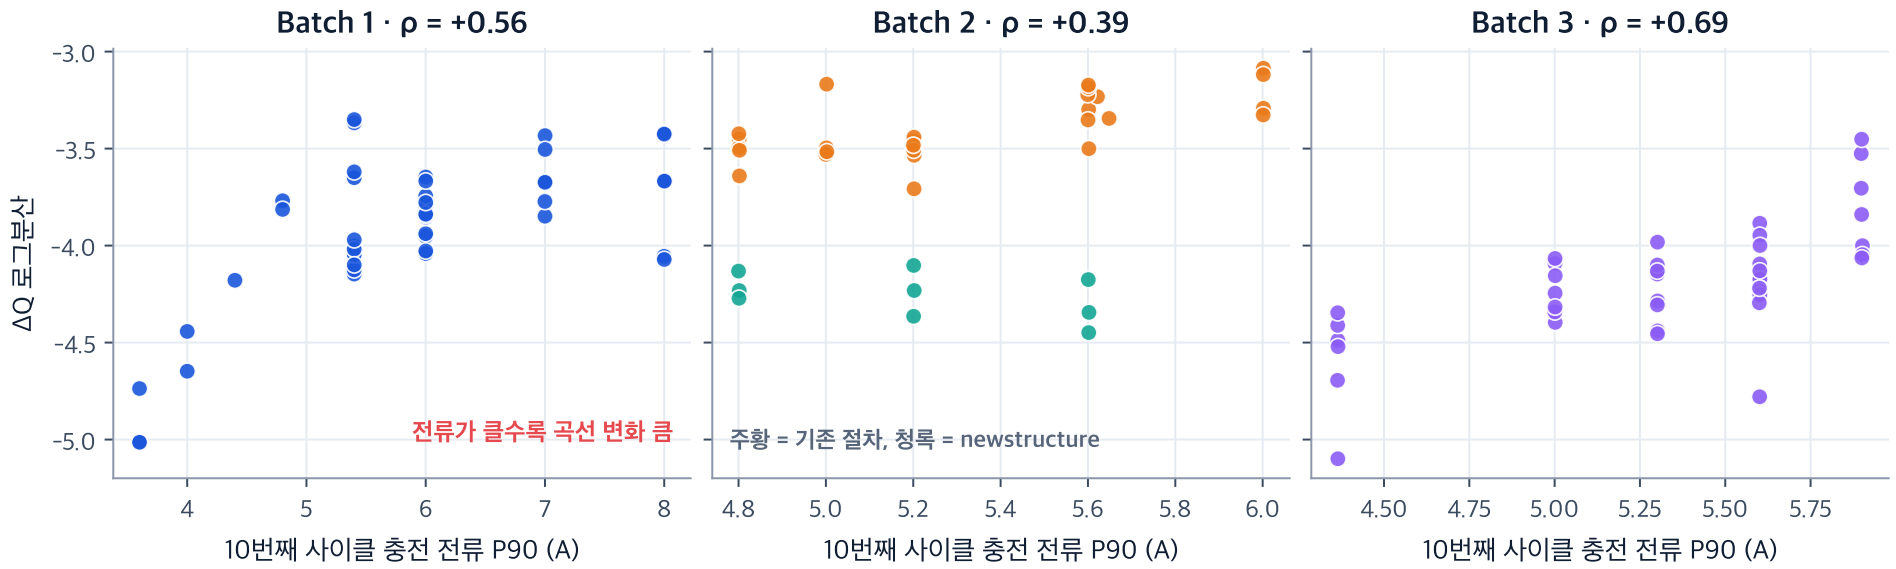
고속 충전 셀이 정말 짧은가?

Batch 1에서만 그렇다. ρ = -0.48 / +0.06 / -0.23. 첫 C-rate만으로는 설명이 안 된다.

시사점 충전 정책은 수명에 영향을 주지만 단독 피처로는 약하다 → 보조 후보.

Q4-2. 충전 전류 패턴과 열화 속도는 상관이 있는가?

그림 7. 10회차 충전 전류 vs 초기 열화(ΔQ 로그분산) x = 10회차 충전 전류의 90번째 백분위수(A) · 한 점 = 셀 1개



상관이 있는가?

있다. 충전 전류가 클수록 초기 열화가 크다. ρ = +0.56 / +0.39 / +0.69.

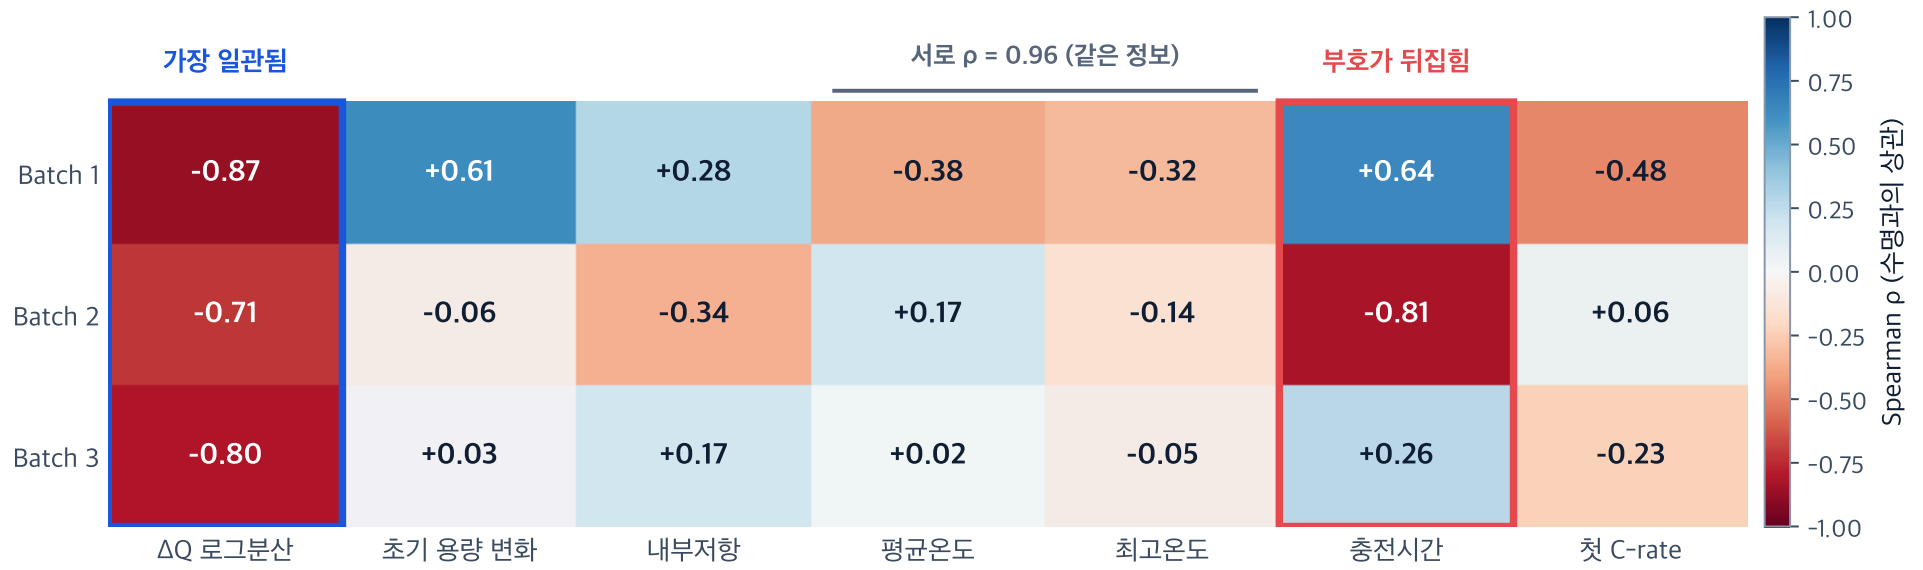
새로운 정보인가?

아니다. 첫 C-rate와 ρ 0.97로 사실상 같은 정보다.

시사점 충전 전류와 첫 C-rate 중 하나만 후보로 둔다.

Q5. 어떤 신호가 수명과 연관되어 있는가?

그림 8. 초기 피처 vs 수명 상관 (Spearman ρ) 10~100회차 피처 · 세 배치에서 부호가 같은지 본다



가장 강한 관계는?

ΔQ 로그분산. 세 배치 모두 -0.71 ~ -0.87로 일관된다.

믿기 어려운 신호는?

충전시간: +0.64 → -0.81로 **배치마다 부호가 뒤집힌다**.

멀티콜리니어리티는?

있다. 평균·최고온도 0.96, ΔQ 분산·최솟값 -0.99.

시사점 ΔQ를 중심에 두고, 서로 겹치는 피처는 하나만 쓴다.

EDA에서 확인한 데이터 특성이 모델 설계를 어떻게 정했나?

EDA에서 확인한 것		설계 결정	근거
배치마다 수명 분포가 크게 다르다	→	**Batch 1 학습 · Batch 2는 마지막에 1회 테스트**	Q1-1
Batch 2·3에 다른 실험 절차가 섞여 있다	→	**Batch 2 성능은 전체 + 절차별로 보고**	Q1-2
Knee는 수명이 끝나갈 때 나타난다	→	**입력은 100회차까지의 관측값만**	Q2
ΔQ 로그분산만 세 배치에서 일관 (-0.71~-0.87)	→	**1순위 피처**	Q3, Q5
ΔQ와 수명이 거의 직선 (Pearson -0.89)	→	**Ridge(선형)를 주 후보로**	Q3-2
충전 조건은 배치마다 불안정, 전류와 C-rate가 겹침	→	**둘 중 하나만 보조 후보**	Q4
온도끼리, ΔQ 통계끼리 강하게 겹침	→	**겹치는 쌍은 하나만 · 규제 모델**	Q5
550회 기준이면 학습 데이터에 단수명이 0셀	→	**분류 대신 회귀**	전략 2
같은 충전 정책의 셀이 2개씩 있다	→	**정책 단위로 데이터 분할**	Q1-1, 전략 3-1

요약 모든 설계 결정은 EDA에서 확인한 데이터 특성에서 나왔다.

근거 = 해당 질문 쪽의 그래프

전략 1-1. 어떤 피처를 만드는가?

10회차 기준 곡선·전류 → **100회차** 비교 곡선·용량 → **101회 이후** 사용 금지

피처	계산	근거
ΔQ 로그분산	log10 Var[Q(100) − Q(10)]	Q3, Q5
초기 용량 변화	Qd(100) − Qd(10)	Q2
충전 전류	10회차 충전 전류 90백분위수	Q4-2
온도·저항	10~100회 평균온도·내부저항 중앙값	Q5
충전 정책	첫 C-rate, 전환 SOC, 두 번째 C-rate	Q4-1

무엇을 만드나?

100회차까지 관측한 값으로 8개 피처. 핵심은 ΔQ 로그분산.

무엇을 넣지 않나?

101회 이후 값, Knee, 수명 종료 정보, 배치 번호. 예측 시점에 알 수 없거나 정답이 새는 값이다.

이상치는?

제거하지 않는다. 극단 수명 셀도 예측해야 할 대상이다.

설계 결정 ΔQ 로그분산 1개로 시작해 피처를 한 묶음씩 더한다.

전략 1-2. 유의미한 변수를 어떻게 선별하는가?

피처와 수명의 상관 (ρ)

피처	Batch 1	Batch 2	Batch 3	판단
ΔQ 로그분산	-0.87	-0.71	-0.80	**채택**
충전 전류	-0.51	-0.30	-0.56	**추가 후보**
초기 용량 변화	+0.61	-0.06	+0.03	**비교 후보**
평균온도	-0.38	+0.17	+0.02	**비교 후보**
내부저항	+0.28	-0.34	+0.17	**비교 후보**
첫 C-rate	-0.48	+0.06	-0.23	**대체 후보**

추가 순서

A
ΔQ 로그분산

→

B
A + 충전 전류

→

C
B + 온도 또는 저항

선별 기준은?

Batch 1 교차검증에서 오차(MAPE)가 줄어드는 피처만 남긴다.

겹치는 피처는?

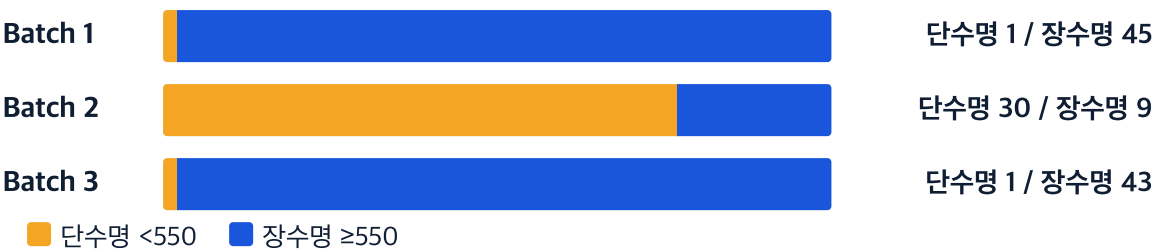
쌍에서 하나만 쓴다. 첫 C-rate↔충전 전류 0.97, 평균↔최고온도 0.96.

선별 원칙 A → B → C 순서로 더하며 오차가 줄어드는지 확인한다.

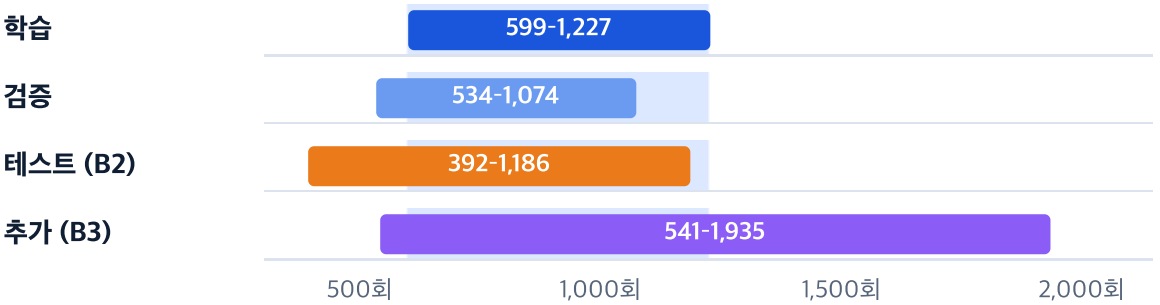
판단은 Batch 1 기준

전략 2. 회귀와 분류 중 무엇을 하는가?

논문 분류 기준(550회)으로 나누면



수명 범위: 학습 vs 평가



선택

회귀. 550회 기준이면 학습 데이터(Batch 1)에 단수명이 1셀뿐이라 분류를 학습할 수 없다.

Target Variable

cycle_life. 오른쪽으로 치우쳐(왜도 +0.44) log10 변환도 비교한다.

평가 지표

MAPE(%). 원논문 목표 9.1%와 비교한다.

선택 Batch 2의 30/39셀은 학습 수명 범위보다 짧다 → 이 구간의 오차를 따로 본다.

분류 레이블 = cycle_life ≥ 550

전략 3-1. 데이터를 어떻게 나누고 처리하는가?

셀 분할 (칸 폭 = 셀 수)



Train 37셀 = 정책 18개를 4-fold 교차검증 · Valid 9셀 = 학습에 없는 정책 5개 · random_state=42

어떻게 나누나?

충전 정책 단위로 Train 37셀(4-fold 교차검증)과 Valid 9셀로 나눈다.

왜 정책 단위인가?

같은 정책의 셀이 학습과 검증에 나뉘면 답을 미리 본 셈이 된다.

전처리는?

표준화는 학습 폴드에서만 맞추고, Batch 2는 최종 모델 선택 뒤 **한 번만** 평가한다.

원칙 모델 선택과 조정은 Batch 1 안에서만 한다.

분할표: model_design_matrix.csv

전략 3-2. 어떤 모델을 후보로 두는가?

후보 모델 (단순한 것부터)

0 중앙값 기준선
교차검증 MAPE 19.7% · 비교 기준

1 Ridge
주 후보 · 직선 관계, 학습 범위 밖도 예측 가능

2 Elastic Net
겹치는 피처 자동 정리

3 얕은 Random Forest
비선형 확인용 · 학습 범위 밖 예측 불가

왜 선형 모델이 주 후보인가?

ΔQ와 수명이 **거의 직선**(Q3-2)이고, Batch 2 셀 상당수가 학습 범위 밖이라(수명 30셀, ΔQ 12셀) 범위를 넘어 예측할 수 있어야 한다.

Random Forest는?

학습 범위 밖을 예측하지 못해 Batch 2 MAPE가 **약 25% 아래로 내려갈 수 없다**. 비교용으로만 둔다.

최종 선택 기준은?

Batch 1 교차검증의 평균 MAPE와 폴드 간 편차.

계획 Ridge → Elastic Net → 얕은 RF 순서로 비교하고, 이득이 작으면 단순한 모델을 택한다.

자료: Severson et al., Nature Energy 4, 383-391 (2019)

참고문헌 및 분석 재현

참고문헌

1. Severson, K. A., Attia, P. M., Jin, N., et al. (2019). Data-driven prediction of battery cycle life before capacity degradation. *Nature Energy*, 4, 383-391. https://doi.org/10.1038/s41560-019-0356-8
   데이터 원출처, 목표 성능(회귀 MAPE 9.1%, 분류 정확도 95.1%)

2. MIT-Stanford Battery Dataset (Data-driven prediction of battery cycle life). Kaggle. https://www.kaggle.com/datasets/itshpark/data-driven-prediction-of-battery-cycle
   분석에 사용한 파일: 2017-05-12(Batch 1), 2018-02-20(Batch 2), 2018-04-12(Batch 3)

분석 재현

순서	스크립트	내용
1	analyze_day1.py	원본 .mat에서 셀별 피처·수명 추출, 제외 셀 목록 저장
2	prepare_model_design.py	정책 단위 Train/Valid/CV 분할 고정(random_state=42), 설계 점검값 계산
3	make_charts.py	보고서 그림 생성
4	build_report.py	보고서 HTML 생성 → PDF 인쇄